



INSTITUT SUPÉRIEUR POLYTECHNIQUE DE MADAGASCAR

Fahaizana · Fampandrosoana · Fihavanana

Costa Verde Hotels

Sujet de hackathon — Examen de rattrapage

Machine Learning & Data Science · M2

1. Contexte et objectif

La chaîne fictive *Costa Verde Hotels* gère des séjours urbains, littoraux, naturels et insulaires dans neuf communautés autonomes espagnoles. Les profils régionaux modifient le prix, la saisonnalité, la durée et les transports prévus.

Vous devez estimer, dès la création d'une réservation, la probabilité que celle-ci soit annulée avant l'arrivée. La cible `reservation_annulee` vaut 1 si annulée et 0 sinon.

Usage de la prédiction

Une probabilité sert à **prioriser un contact préventif**, jamais à annuler automatiquement une réservation.

Toutes les données sont synthétiques. Les différences régionales décrivent uniquement le contexte touristique et opérationnel ; elles ne caractérisent pas des populations.

2. Données disponibles

Le fichier d'entraînement contient **8 005** réservations avec cible, et le test contient **1 995** réservations plus récentes sans cible. Il y a **29** variables explicatives. La date de réservation maximale du train est le 2025-05-25 ; le test commence le 2025-05-26.

Ressources — répertoire ressources/

`reservations_train.csv`, `reservations_test.csv`, `data_dictionary.csv`, `sample_submission.csv` et `readme-model.md`.

Types de données : dates, catégories, prix, durée de séjour, conditions commerciales, historique client et informations hôtelières. Certaines valeurs manquent et une catégorie de canal peut apparaître seulement dans le test.

Région	Profil simulé	Mois forts
Madrid	urbaine affaires	3, 4, 5, 9, 10
Catalogne	urbaine côtière	4, 5, 6, 7, 8, 9
Andalousie	culturelle balnéaire	3, 4, 5, 6, 9, 10
Communauté valencienne	littorale urbaine	5, 6, 7, 8, 9
Îles Baléares	insulaire balnéaire	5, 6, 7, 8, 9
Îles Canaries	insulaire nature	1, 2, 3, 4, 10, 11, 12
Galice	nature patrimoine	5, 6, 7, 8, 9
Aragon	montagne patrimoine	1, 2, 7, 8, 12
Pays basque	urbain nature	4, 5, 6, 7, 8, 9

3. Travail demandé

1. Explorer les données, mesurer le déséquilibre et documenter les valeurs manquantes, les valeurs atypiques et les profils saisonniers/régionaux.
2. Réserver une validation strictement postérieure aux données d'ajustement. En cas d'ajustement d'hyperparamètres ou de calibration, séparer aussi les périodes utilisées pour ces opérations.
3. Construire une baseline reproductible de régression logistique, puis comparer au moins deux autres familles de modèles sur les mêmes périodes.
4. Mesurer F1, précision, rappel et PR-AUC ; mesurer aussi la qualité des probabilités avec le score de Brier et un diagramme de calibration. Justifier le seuil sélectionné exclusivement sur validation.
5. Analyser les faux positifs et les faux négatifs, les résultats selon les périodes et les types de destination, puis décrire une action métier proportionnée.
6. Produire les prédictions sur le test dans son ordre initial, avec la probabilité et la classe. Expliquer les limites de cette expérience synthétique.

Prévention des fuites

Ne jamais apprendre imputations, encodages, seuil ou calibrateur sur le test fourni.

4. Livrables

Un dépôt avec notebook.ipynb exécutable de bout en bout, README.md renseigné selon le canevas et submission.csv ; indiquer les dépendances et graines utilisées.

Format de submission.csv

Exactement les colonnes reservation_id, probabilite_annulation et reservation_annulee ; probabilités entre 0 et 1 et classes 0/1. Aucun identifiant ne doit manquer ou être ajouté.

Présentez oralement vos principaux résultats et réponses individuelles selon les modalités communiquées par l'enseignant. La date et l'heure de remise seront précisées séparément.

5. Évaluation (100 points)

Critère	Points
Analyse et qualité des données	15
Validation temporelle et prévention des fuites	20
Baseline et comparaison des modèles	20
Probabilité, calibration et seuil	15
Analyse des erreurs et stabilité	15
Reproductibilité, rapport et présentation	15
Total	100

Le score sur le test caché complète l'appréciation, sans remplacer la justification de la démarche. Les outils d'IA peuvent être utilisés si chaque membre sait expliquer son travail.